

Chapter07

로지스틱회귀

# 로지스틱회귀의 원리

FASTCAMPUS  
ONLINE

금융공학/퀀트 I

강사. 장순용

# I 키포인트

- 로지스틱 회귀의 원리.
- 로지스틱 회귀를 적용한 학습과 예측.




## I 통계 예측모형

## 통계 예측모형


수치 예측

$$Y = 13.45, 73, 9.5, \dots$$

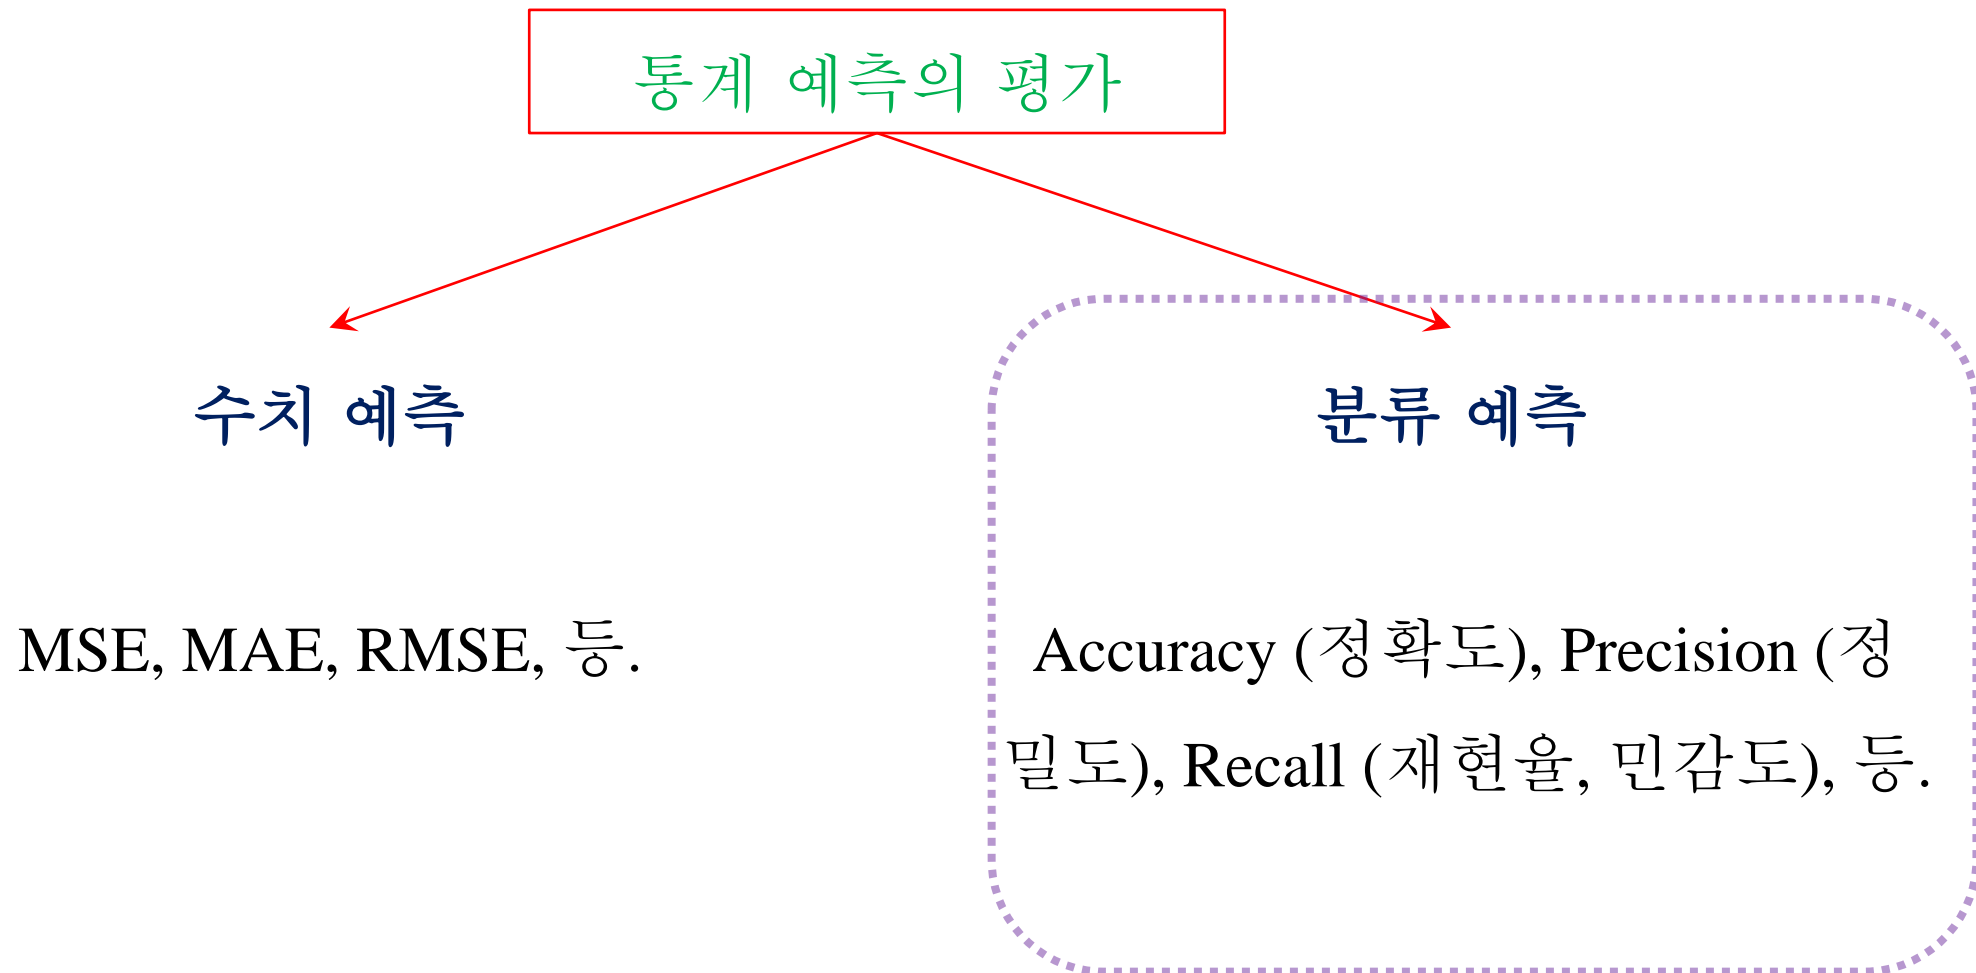


분류 예측

$$Y = \text{red}, \text{green}, \text{blue}, \dots$$



# I 통계 예측모형



# I 로지스틱 회귀 개요

- 로지스틱 회귀는 대표적인 분류 예측 방법이다.
- 한개 이상의 독립변수 (설명변수)가 있다:  $X_1, X_2, \dots, X_K$
- 한개의 종속변수가 있다:  $Y$
- 종속변수의 값은 0 또는 1이어야만 한다: 이분법적인 상황을 모델링.
- 종속변수의 값 예측  $\Leftarrow$  조건부 확률 계산.

## I 로지스틱회귀 기초

- $k$  개의 독립변수 (설명변수)가 있다고 가정한다.  
→ 가능한 값에 대해서는 제약이 없다.

$$X_1, X_2, \dots, X_K.$$

# I 로지스틱회귀 기초

- 그리고 한개의 종속변수가 있다고 가정한다.

→ 그런데 가능한 값은 0과 1로 국한됨.

$$Y = \begin{cases} 1 \\ 0 \end{cases}$$

# I 로지스틱회귀 기초

- 즉, 이분법적인 상황이다.

$$Y = \begin{cases} \text{참} (True) \\ \text{거짓} (False) \end{cases}$$



# I 로지스틱회귀 기초

- 즉, 이분법적인 상황이다.

$$Y = \begin{cases} \text{유형 } a \\ \text{유형 } b \end{cases}$$

# I 로지스틱회귀 원리

- 이제는 독립변수  $\{X_i\}$ 를 선형조합하여  $S$  변수 (logit)을 만든다.

$$S = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K$$



독립변수

(데이터로 값이 주어짐)

## I 로지스틱회귀 원리

- 이제는 독립변수  $\{X_i\}$ 를 선형조합하여  $S$  변수 (logit)을 만든다.

$$S = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K$$



계수

(학습을 통해서 밝혀냄)


# I 로지스틱회귀 원리

- 종속변수  $Y$  의 값이 1이 될 조건부 확률  $P(Y = 1|\{x_i\})$ 은 “로지스틱 함수”또는 “Sigmoid 함수”를 사용해서 계산된다.


$$f(S) = \frac{e^S}{1 + e^S}$$

→ 인공신경망에서 “활성화 함수” (activation function)의 역할을 함.

# I 로지스틱회귀 원리




# I 로지스틱회귀 원리





## I 로지스틱회귀 원리



# I 로지스틱회귀 학습

- 학습이란 모형의 파라미터,  $\beta$  계수들의 값을 구하는 것.

$$S = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K$$

$$f(S) = \frac{e^S}{1+e^S}$$

## I 로지스틱회귀 학습

- 로그우도  $L$  을 최소화하는 방법으로  $\beta$  계수들의 값을 구할 수 있다.
- 로그우도  $L$  은 일종의 “손실함수”이다.
  - 예측 오류에 의한 “손실”을 최소화 하고자 한다.

# I 로지스틱회귀 학습

- 로그우도  $L$  의 수식은 다음과 같다:

$$L(\vec{\beta}) = - \sum_{i=1}^N \text{Log} \left( 1 + e^{-y_i \vec{\beta}^t \vec{x}_i} \right)$$

- $L$ 의 값은 gradient 방향으로 증가율 최고.  
→ -gradient 방향으로는 감소율 최고.

## I 로지스틱회귀 학습

- $L$ 의 gradient는 다음과 같이 구할 수 있다.

$$\vec{\nabla} L = - \sum_{i=1}^N \frac{y_i \vec{x}_i e^{-\vec{\beta}^t \vec{x}_i}}{1 + e^{-\vec{\beta}^t \vec{x}_i}}$$

→  $L$ 을 미분하여 구할 수 있다.

→  $\vec{x}_i$ 와  $y_i$ 는 실제 데이터 값을 의미한다.


## I 로지스틱회귀 학습

- Gradient descent 알고리즘: 감소를 최고인  $-\overrightarrow{\nabla L}$ 로 반복적으로 이동.
  - a).  $\vec{\beta}$ 를 임의의 값으로 초기화 한다.
  - b). Gradient  $\overrightarrow{\nabla L}$ 를 계산한다.
  - c).  $\vec{\beta}$ 를  $\vec{\beta} - \eta \overrightarrow{\nabla L}$ 와 같이 갱신한다. “Learning rate”  $\eta$ 로 수렴 속도 조절.
  - d). 스텝 b)로 돌아가서 일정 횟수만큼 반복한다.




## I 로지스틱회귀 학습

- Gradient descent 알고리즘: 감소율 최고인  $-\vec{\nabla}L$ 로 반복적으로 이동.




# I 로지스틱회귀 학습



모델의 파라미터, 즉  $\{\beta_i\}$ 를 학습용 데이터를 사용하여 계산해 놓는다.

## I 로지스틱회귀 예측



독립변수의 값이 새롭게 주어졌을 때  $\{x_i'\}$ , 모르는 상태인 종속변수의 값  $y'$  을 계산을 통해서 알아낸다.



“조건부 확률”

$P(Y' = 1|\{x_i'\}) > \text{기준확률?}$

$\rightarrow y' = 1 \text{ or } 0$

I 끝.

감사합니다.

