

Chapter.05  
리스크 관리

# 현대 포트폴리오 이론 (MPT) III

M T W T F S S

FASTCAMPUS  
ONLINE

금융공학/퀀트 I

강사. 장순용


# I 키포인트

- 효율적 투자선 (Efficient frontier).
- 두 개의 펀드 이론 (Two fund theorem).
- Long 포지션에 국한된 포트폴리오 (난이도 上, **option**).
- Quadratic programming (난이도 上, **option**).



# I 효율적 투자선 (Efficient frontier)

- $r_{port}$ 를 정해놓고  $\sigma_{port}$ 를 최적화하여 다음 그래프를 그릴 수 있다.




⇒ 곡선의 상위 부분 (적색) 을 “**효율적 투자선**”이라 부른다.

⇒ 목표하는 수익률 대비 **최소의 리스크** 지점이다.

# I 효율적 투자선 (Efficient frontier)

- $r_{port}$ 를 정해놓고  $\sigma_{port}$ 를 최적화하여 다음 그래프를 그릴 수 있다.



⇒ 매번  $r_{port}$ 를 조금씩 변경하고 최적화를 실시해야 하는 번거로움이 따른다.

# I 두 개의 펀드 이론 (Two fund theorem)

- 먼저 효율적 투자선상의 두 개의 좌표 (포트폴리오)를 전제 한다.

예). 두 개의 좌표는 A 포인트와 T 포인트가 될 수 있다.

⇒  $(\sigma_1, r_1)$ 과  $(\sigma_2, r_2)$ 로 표기하기로 한다.

⇒ 각각의 가중치 벡터는  $\vec{w}_1$ 과  $\vec{w}_2$ 로 표기한다.

⇒ 효율적 투자선의 다른 좌표는  $\vec{w}_1$ 과  $\vec{w}_2$ 의 선형 조합으로 얻을 수 있다.

$$\vec{w} = (1 - \alpha) \vec{w}_1 + \alpha \vec{w}_2$$

⇒  $\alpha$ 를 변경시키며  $\sigma$ 와  $r$ 을 계산해서 효율적 투자선을 그릴 수 있다. (최적화 불필요!)

## I Long 포지션에 국한된 포트폴리오 (난이도 上)

- 지금까지는 가중치  $w_i$ 가 양수 (+) 또는 음수 (-)가 될 수 있었다.
  - ⇒ 가중치  $w_i$ 가 양수이면 Long (매수) 포지션을 의미한다.
  - ⇒ 가중치  $w_i$ 가 음수이면 Short (매도) 포지션을 의미한다.
- 그런데 주식과 같은 자산을 Short (공매도) 포지션을 두기에는 현실적으로 어려울 수도 있다.
  - ⇒ 모든 가중치  $w_i$ 가 양수라는 **부등식** 제약을 두기로 한다:  $\vec{w} \geq \vec{0}$
  - ⇒ Long 포지션에 국한된 포트폴리오를 만들고자 한다.

# I Quadratic Programming (난이도 상)

- 다음과 같이 두 개의 등식으로 성립되는 제한조건과 한 개의 부등식으로 성립되는 제한조건을 전제한다.

⇒ 수익률 고정:  $r_{port} = \sum_{i=1}^P w_i r_i$

⇒ 정규화:  $\sum_{i=1}^P w_i = 1$

⇒ Long 포지션에 국한:  $w_i \geq 0$

# I Quadratic Programming (난이도 上)

- 라그랑주 함수는 다음과 같다.

$$\mathcal{L} = \frac{1}{2} \bar{\mathbf{w}}^t \tilde{\Sigma} \bar{\mathbf{w}} - \frac{1}{c} \sum_{i=1}^N \text{Log}(w_i) - \lambda_1 (\bar{\mathbf{w}} \cdot \bar{\mathbf{1}} - 1) - \lambda_2 (\bar{\mathbf{w}} \cdot \bar{\mathbf{r}} - r_{port})$$

- ⇒  $-\frac{1}{c} \sum_{i=1}^N \text{Log}(w_i)$ 가 바로 부등식에 의한 제약을 나타낸다.
- ⇒ 파라미터  $c$ 가 작을수록 강한 제한조건이 적용되는 것이다.
- ⇒ 파라미터  $c$ 가 클수록 약한 제한조건이 적용되는 것이다.
- ⇒ 로그함수는 **비선형**이기 때문에 선형 방정식으로 그 해를 구할 수 없다.



# I Quadratic Programming (난이도 上)

- 라그랑주 함수를 다음과 같이 표현할 수 있다.

$$\mathcal{L}(\vec{w}, \vec{\lambda}) = f(\vec{w}) - \vec{\lambda} \cdot (\tilde{A} \vec{w} - \vec{b})$$

$$f(\vec{w}) = \frac{1}{2} \vec{w}^t \tilde{\Sigma} \vec{w} - \frac{1}{c} \sum_{i=1}^N \text{Log}(w_i)$$

$$\tilde{A} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ r_1 & r_2 & \cdots & r_N \end{pmatrix}, \vec{b} = \begin{pmatrix} 1 \\ r_{port} \end{pmatrix}, \vec{\lambda} = \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix}$$

# I Quadratic Programming (난이도 上)

- 비선형 방정식을 단 한번에 풀기는 어렵다.
- ⇒ 비선형 방정식을 **근접하여** 선형 방정식化하는 방법을 적용한다.
- ⇒ 최적화된 해로 조금씩 수렴해 나가는 방식을 적용한다.
- ⇒ 라그랑주 함수의 최적화 조건은 다음과 같이 함축적으로 표현할 수 있다.

$$\vec{\nabla}_{\vec{w}} \mathcal{L}(\vec{w}, \vec{\lambda}) + \tilde{\nabla}_{\vec{w}}^2 \mathcal{L}(\vec{w}, \vec{\lambda}) \overrightarrow{\Delta w} + \tilde{\nabla}_{\vec{w}, \vec{\lambda}}^2 \mathcal{L}(\vec{w}, \vec{\lambda}) \overrightarrow{\Delta \lambda} = \vec{0}$$

$$\vec{\nabla}_{\vec{\lambda}} \mathcal{L}(\vec{w}, \vec{\lambda}) + \tilde{\nabla}_{\vec{w}, \vec{\lambda}}^2 \mathcal{L}(\vec{w}, \vec{\lambda}) \overrightarrow{\Delta w} = \vec{0}$$

- ⇒ 도출 방법은 **부록** 참고.

# I Quadratic Programming (난이도 上)

- 실제 라그랑주 함수를 대입해서 정리하면 다음과 같은 방정식을 얻을 수 있다. 그리고  $\overrightarrow{\Delta w}$  와  $\overrightarrow{\Delta \lambda}$ 가 방정식의 해이다.

$$\begin{pmatrix} \tilde{\Sigma} + \frac{1}{c} \overrightarrow{\Phi} & -\tilde{A}^t \\ \tilde{A} & \overrightarrow{0} \end{pmatrix} \begin{pmatrix} \overrightarrow{\Delta w} \\ \overrightarrow{\Delta \lambda} \end{pmatrix} = - \begin{pmatrix} \tilde{\Sigma} \overrightarrow{w} \\ \overrightarrow{d}(\overrightarrow{w}) \end{pmatrix}$$

$$\overrightarrow{\Phi} = \begin{pmatrix} \frac{1}{(w_1)^2} & 0 & \dots & 0 \\ 0 & \frac{1}{(w_2)^2} & 0 & \vdots \\ \vdots & 0 & \ddots & 0 \\ 0 & \dots & 0 & \frac{1}{(w_P)^2} \end{pmatrix}, \quad \overrightarrow{d}(\overrightarrow{w}) = \tilde{A} \overrightarrow{w} - \overrightarrow{b}$$

# I Quadratic Programming (난이도 上) : 알고리즘

1. 모든 제한조건을 충족하는  $\vec{w}$ 와  $\vec{\lambda}$ 의 초기값을 “선택”한다. 또한, 파라미터  $c$ 에 임의의 작은 값을 부여한다. 이것은 **강한 부등식** 제한조건을 적용하는 것을 의미한다.
2. 방정식의 해  $\overrightarrow{\Delta w}$ 와  $\overrightarrow{\Delta \lambda}$ 를 구한다.
3.  $\vec{w} \rightarrow \vec{w} + \overrightarrow{\Delta w}$  그리고  $\vec{\lambda} \rightarrow \vec{\lambda} + \overrightarrow{\Delta \lambda}$ 와 같이 최적화 지점으로 한 스텝 수렴한다.
4. 스텝 2에서부터 일정 회수를 반복한다.

# I Quadratic Programming (난이도 上) : 알고리즘

5. 수렴된  $\vec{w}$ 와  $\vec{\lambda}$  을 초기값으로 하며 파라미터  $c$ 의 값을 증가시키며 반복한다. 이것은 부등식 제한조건  $\vec{w} \geq \vec{0}$ 을 조금씩 **완화해** 가는 것을 의미한다.

⇒ 만약에, 벡터  $\vec{w}$ 의 성분 중에서 0으로 수렴하는 것이 있다면,

너무 강한 제한조건은 0으로의 수렴을 방해할 수 있기 때문이다.

⇒ 아무리 제한조건이 약해지더라도  $-\frac{1}{c} \sum_{i=1}^N \text{Log}(w_i)$ 때문에 절대로

가중치가 0을 지나서 음수 (short)로 넘어가는 상황은 발생하지 않는다.

**| 끝.**

**감사합니다.**

