

Chapter. 02

선형대수학 응용

최소자승법과 선형회귀

FASTCAMPUS
ONLINE

금융공학/퀀트 I

강사. 장순용

I 키포인트

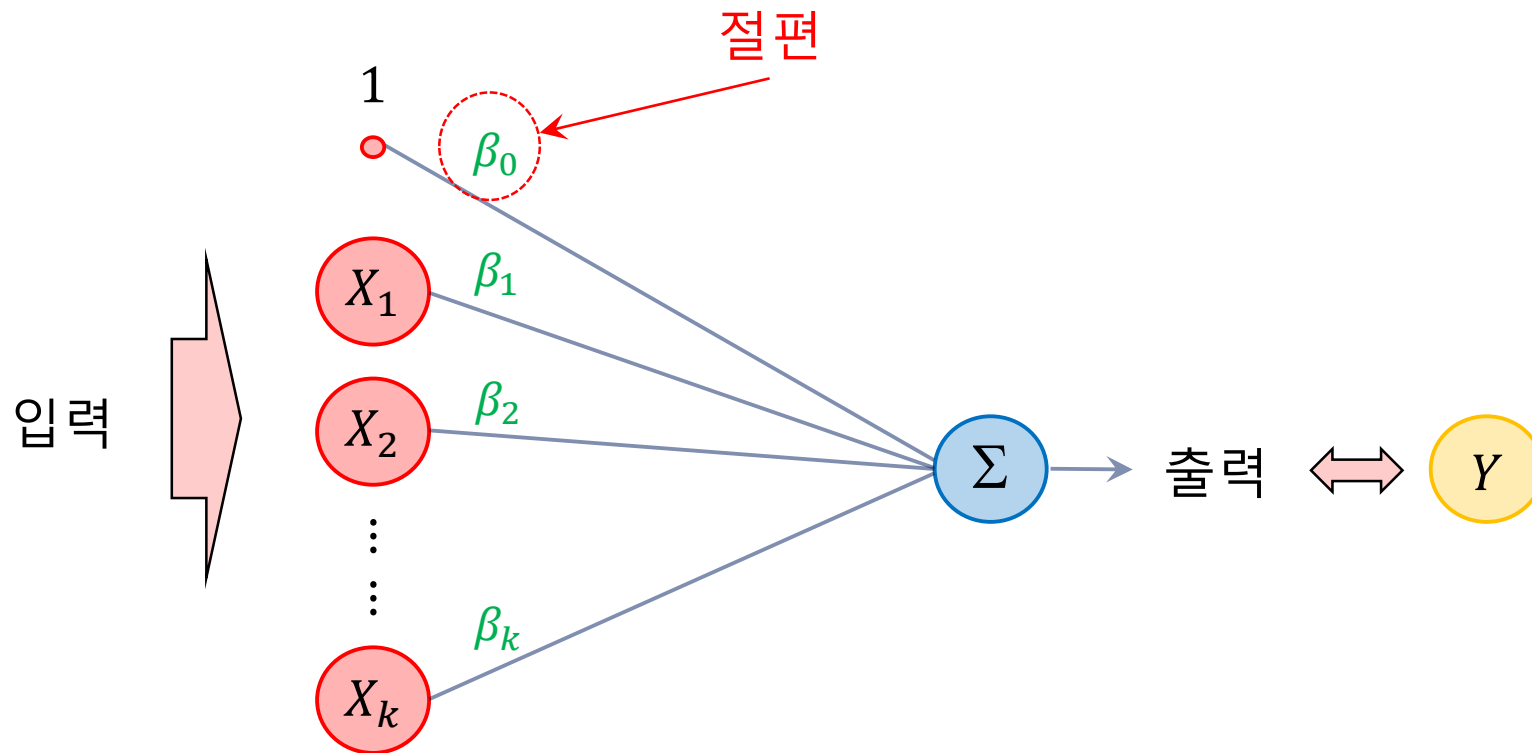
- 선형회귀.
- 최소자승법 (Ordinary Least Squares, OLS).
- 가역행렬의 도출.

I 선형회귀


- 회귀모형:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K + \varepsilon$$

I 선형회귀 구조



I 선형회귀 예측




I 선형회귀 연립방정식

- 개개 방정식:

$$y_j = \beta_0 + \beta_1 x_{j,1} + \beta_2 x_{j,2} + \cdots + \beta_K x_{j,K} + \varepsilon_j$$

$j \in [1, n]$




$n \gg K$

Over-determined!

I 선형회귀 연립방정식


- 선형대수학적 표기:

$$Y = X \beta + \varepsilon$$

I 선형회귀 연립방정식

- 선형대수학적 표기:


$$\mathbf{Y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$


$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

I 선형회귀 연립방정식

- 선형대수학적 표기:


$$Y = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon}$$


$$\mathbf{X} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,K} \\ 1 & x_{2,1} & \cdots & x_{2,K} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,K} \end{bmatrix}$$

I 선형회귀 연립방정식

- 선형대수학적 표기:


$$Y = X \beta + \varepsilon$$


$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_K \end{bmatrix}$$

I 선형회귀 연립방정식

- 선형대수학적 표기:

$$Y = X \beta + \varepsilon$$


$$\varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

I 선형회귀의 OLS 해 도출

- $\|\boldsymbol{\varepsilon}\|^2$ 를 최소화 하는 가장 “근접한 해” $\boldsymbol{\beta}$ 를 도출해 내고자 한다.
- $\|\boldsymbol{\varepsilon}\|^2$ 의 최소값 조건은 다음과 같이 미분으로 나타낼 수 있다.

$$\frac{d\|\boldsymbol{\varepsilon}\|^2}{d\boldsymbol{\beta}} = 0$$

I 선형회귀의 OLS 해 도출

- 선형 방정식을 대입하여 전개해 본다:

$$\begin{aligned}
 \frac{d\|\boldsymbol{\varepsilon}\|^2}{d\boldsymbol{\beta}} &= \frac{d\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2}{d\boldsymbol{\beta}} \\
 &= \frac{d\{(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^t(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})\}}{d\boldsymbol{\beta}} \\
 &= \frac{d\{\mathbf{Y}^t\mathbf{Y} - \boldsymbol{\beta}^t\mathbf{X}^t\mathbf{Y} - \mathbf{Y}^t\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}^t\mathbf{X}^t\mathbf{X}\boldsymbol{\beta}\}}{d\boldsymbol{\beta}} \\
 &= -2\mathbf{X}^t\mathbf{Y} + 2\mathbf{X}^t\mathbf{X}\boldsymbol{\beta} = 0
 \end{aligned}$$

I 선형회귀의 OLS 해 도출

- 이전 슬라이드의 조건을 정리하면 다음 OLS 해를 얻는다:

$$\boldsymbol{\beta} = [(\boldsymbol{X}^t \boldsymbol{X})^{-1} \boldsymbol{X}^t] \boldsymbol{Y}$$



$\|\boldsymbol{\varepsilon}\|^2$ 를 최소화 하는 계수벡터이다.

I 선형회귀의 OLS 해 도출

- 이전 슬라이드의 조건을 정리하면 다음 OLS 해를 얻는다:

$$\beta = [(X^t X)^{-1} X^t] Y$$



가역행렬 !!!

(Pseudoinverse)

⇒ 미지수보다 방정식 (조건)이 더 많은 상황이었다.

I 선형회귀의 OLS 해 도출

- 이전 슬라이드의 조건을 정리하면 다음 OLS 해를 얻는다:

$$\beta = [(X^t X)^{-1} X^t] Y$$

⇒ 다음과 같이 **단 1행의** 코딩으로 구현할 수 있다 (Python).

```
beta = np.dot(np.linalg.inv(np.dot(X.T,X)),np.dot(X.T,Y))
```

| 끝.

감사합니다.

